NYT 新闻文本分类
课程实验报告

侯嘉栋
2311671

摘要

本报告按照课程作业的三个任务，在统一 NYT 测试集上比较七种文本分类方法。Task 1 使用二值词袋、词频和 TF-IDF，Task 2 使用三种来源的 100 维平均词向量，两项任务均以逻辑回归分类；Task 3 按照规定微调 BERT-base-uncased，输入长度为 64，训练三轮。实验在 13,007 篇清洗后新闻、29 个类别上采用随机 80/10/10 划分，报告 Accuracy 与 Macro-F1。主实验中，TF-IDF 的准确率最高，为 94.01%；词频的 Macro-F1 最高，为 83.61%。NYT Word2Vec 是表现最好的平均词向量，Macro-F1 为 81.85%；规定设置下 BERT 为 62.97%。随后通过输入长度、类别加权、池化、训练预算和文本位置等对照，共完成 233 组配置。五个划分与三个训练种子的结果表明，表示方法的排名受到可见文本、类别分布和优化预算的共同影响。参考划分上的十轮普通损失 BERT-512 达到 $86.38 \pm 0.51\%$ Macro-F1，并反转三轮时的损失排名。

1 课程目标与报告结构

本次作业考察不同文本表示方法的原理、实现和分类效果。报告正文依次对应三个任务：Task 1 为三种词袋表示与逻辑回归（第 3 节），Task 2 为 GloVe、AG News Word2Vec 和 NYT Word2Vec 的平均词向量分类（第 4 节），Task 3 为 BERT 的规定设置微调（第 5 节）。每一节集中给出任务要求、方法、实现设置及测试结果，完整七方法汇总见表 6。

三种表示保留的信息不同：词袋记录具体词汇，平均词向量将全文压缩为 100 维语义表示，BERT 建模可见词元之间的上下文关系。NYT 中体育主题样本较多，部分政策与科学主题样本较少，因此同时报告按文档计算的准确率与按类别等权平均的 Macro-F1。第 6 节进一步探索输入范围、类别加权、池化和优化预算，分析主实验差异的可能来源。

2 共用数据与实验设置

2.1 数据来源与清洗

NYT 数据来自 WeSHClass 的公开发布版本，与弱监督层次文本分类研究关联 (Meng et al., 2019)。将 `dataset.txt` 与 `labels.txt` 按行对齐，转换为包含 `text` 和 `label` 的数据表，保留原始 29 个标签。AG News 来自 Zhang et al. (2015) 对应的公开数据分发版本，实验仅使用训练文本学习词向量。资源地址列于附录 B。

原始 NYT 包含 13,081 条记录。划分前移除两组相同文本但标签冲突的记录，共四条；随后对其余文本去重，每篇文档保留一条记录，再移除 70 条。清洗后得到 13,007 篇唯一文档，相同文本不会同时进入不同数据子集。按照传统模型的分词方式，平均文档长度为 653.2 个词，中位数为 686。

2.2 统一划分与训练范围

使用 NumPy `RandomState(42)` 对清洗后的行号随机置换。前 $\lfloor 0.8N \rfloor$ 个样本作为训练集，接下来的 $\lfloor 0.1N \rfloor$ 个样本作为验证集，其余作为测试集。实际划分数量为 10,405、1,300 和 1,302。该划分采用随机打乱，不进行分层抽样，所有主实验模型共用这些行号。

NYT 词表、TF-IDF 权重、NYT Word2Vec、标准化参数和分类器参数均仅使用训练集拟合。GloVe 与 BERT 初始参数来自外部预训练资源，BERT 随后仅在 NYT 训练集上微调。AG News Word2Vec 使用外部训练语料。验证和测试文本使用拟合后的表示进行转换。

验证集用于选择模型配置，选定模型在相同的 1,302 篇测试文档上评价。各任务均保留训练、验证、测试的独立用途，不将验证文档并入训练集重新拟合。

2.3 评价指标与类别分布

设评价集有 M 篇文档，真实标签为 y_d，预测标签为 $\hat{y}_d$，准确率与 Macro-F1 定义为

$$\text{Accuracy} = \frac{1}{M}\sum_{d=1}^{M} \mathbb{1}[\hat{y}_d = y_d], \qquad \text{Macro-F1} = \frac{1}{29}\sum_{k=1}^{29} \frac{2\text{TP}_k}{2\text{TP}_k + \text{FP}_k + \text{FN}_k}. \tag{1}$$

分母为零时，类别 F1 定义为零。所有分数以百分比报告，分数差异以百分点描述，差值由未舍入的分数计算。

参考划分的训练集类别大小从堕胎的 22 篇到棒球的 1,795 篇不等。七个体育类别占测试文档的 68.28%。若始终预测训练集中最大的棒球类别，测试准确率为 16.28%，Macro-F1 为 0.97%。附录 A 的完整类别计数说明，仅凭准确率难以评价模型在不同主题上的分类能力。

12 个低频类别仅包含参考测试集 1,302 篇文档中的 82 篇，占 6.30%，却占 Macro-F1 类别项的 41.38%。因此，模型可能通过更好地识别高频主题提升准确率，同时失去对若干小类别的识别能力。准确率回答“有多少文档分对”，Macro-F1 则回答“各类别等权时，整体识别能力如何”。两个指标的分歧是理解任务的线索，并非评价结果相互矛盾。

2.4 实现环境与保存记录

主实验的 Python、NumPy、PyTorch 以及打乱训练样本的 DataLoader 均设置种子 42。Word2Vec 使用一个 worker，主实验 CPU 线程数为 8。重复划分的传统模型每个 worker 使用四个 CPU 线程，独立 BERT 配置在四张 H100 上运行。环境包含 Python 3.10.16、scikit-learn 1.7.2、Gensim 4.4.0、PyTorch 2.9.0 与 CUDA 12.6，以及 Transformers 4.57.3。实验记录保存验证参数搜索、划分行号、逐文档预测、逐类指标、混淆矩阵和 BERT 训练历史。附录 B 给出运行命令与实际耗时。

3 Task 1：词袋表示与逻辑回归

本任务使用二值词袋、Word Frequency 和 TF-IDF 三种表示，分别训练逻辑回归，并在 NYT 测试集上报告 Accuracy 与 Macro-F1。三种方法共用分词规则、训练词表及分类器参数搜索范围，比较词是否出现、出现次数和词的重要性加权带来的差异。

3.1 分词与稀疏词汇表示

六种传统模型先将文本转为小写，再通过正则表达式 `[a-z]+(?:'[a-z]+)?` 提取英文单词及词内撇号。分词保留重复出现的单词，不包含数字和其他标点，不移除停用词。词表 V 由 NYT 训练集中出现的全部词元构成，大小为 $|V| = 80,350$。验证集和测试集使用该固定词表转换。

设 c_{di} 表示词表中第 i 个词在文档 d 中的出现次数。二值词袋和词频表示使用相同的向量坐标，但赋值不同：

$$x_{di}^{\text{binary}} = \mathbb{1}[c_{di} > 0], \qquad x_{di}^{\text{count}} = c_{di}. \tag{2}$$

二值特征只记录词是否出现，词频特征还保留重复出现的次数。两种表示均不记录词序。评价时，训练词表之外的词不会产生新的特征坐标。

TF-IDF 根据词在训练文档中的普遍程度调整词频。设训练文档数为 N，包含第 i 个词的文档数为 df_i，实现采用平滑逆文档频率并对文档向量进行 L2 归一化：

$$a_{di} = c_{di}\left[\log\left(\frac{1+N}{1+\text{df}_i}\right) + 1\right], \qquad x_d^{\text{tfidf}} = \frac{a_d}{\|a_d\|_2}. \tag{3}$$

逆文档频率仅使用训练集拟合，词频项采用原始计数，不进行对数缩放。若文档中没有训练词表内的词，则其向量为零。L2 归一化减少了文档长度对特征整体尺度的直接影响。

3.2 逻辑回归与模型选择

六种固定表示统一训练多类别逻辑回归。对于特征向量 x 和类别 k，预测概率为

$$p(y = k \mid x) = \frac{\exp(w_k^\top x + b_k)}{\sum_{j=1}^{29} \exp(w_j^\top x + b_j)}. \tag{4}$$

模型输出概率最大的类别。训练采用带 L2 正则的多类别交叉熵、`lbfgs` 求解器以及最多 2,000 次迭代。每种表示分别从 $\{0.1, 1, 10\}$ 中选择逆正则化参数 C。

每种表示选择验证集 Macro-F1 最高的 C，分数相同时保留更小值。二值、词频和归一化 TF-IDF 特征按上述定义直接输入分类器。六种传统方法使用 scikit-learn 实现 (Pedregosa et al., 2011)，对训练样本赋予相同权重；Task 2 复用本节的逻辑回归及参数选择规则。

3.3 结果与分析

表 1 给出 Task 1 的结果。TF-IDF 的测试准确率最高，为 94.01%；词频方法的测试 Macro-F1 最高，为 83.61%。词频在两个测试指标上均超过二值词袋。本次实验中，重复出现的词汇信息有助于分类，而经过归一化和稀有词加权的 TF-IDF 在规定设置下获得最多的正确预测。

表 1: Task 1 的验证与测试结果（%）。三种表示均使用逻辑回归，按验证集 Macro-F1 选择 C。

	验证集		测试集		
方法	准确率	Macro-F1	准确率	Macro-F1	选择
二值词袋	94.38	84.86	92.47	80.47	$C = 10$
词频	93.69	84.02	93.63	83.61	$C = 1$
TF-IDF	95.00	84.86	94.01	82.85	$C = 10$

两个领先的稀疏方法体现了不同评价指标的侧重。TF-IDF 正确预测 1,302 篇测试文档中的 1,224 篇，词频正确预测 1,219 篇。词频更高的 Macro-F1 反映其按类别等权平均后的优势。例如，词频在环境类别上取得非零 F1，TF-IDF 则没有正确识别该类别的五篇测试文档。图 5 展示七种方法的准确率与 Macro-F1 差距。

领先方法的错误并不完全相同。 逐文档对照显示，词频与 TF-IDF 共同正确预测 1,209 篇，共同错误预测 68 篇；另有 10 篇仅词频正确、15 篇仅 TF-IDF 正确。因此，TF-IDF 多分对的五篇是相互抵消后的净差值，而非在所有文档上都更好。12 个低频类别的 Macro-F1 分别为 76.48% 和 73.71%，词频领先。实际选择应依据评价目标，而不宜仅凭 0.38 个百分点的准确率差异确定唯一优胜者。

为什么加权有效，却不一定对所有类别有效。 重复出现的主题词可以增强词频证据，TF-IDF 则削弱普遍词的贡献并归一化文档尺度。这些变化可能改善整体主题判断，同时改变小类别的精确率与召回率平衡。但词频到 TF-IDF 的对照同时改变 IDF 加权与 L2 归一化，且各表示分别选择 C。本实验识别的是有效的完整流程，不能将每项提升单独归因于“稀有词加权”。

词频方法将五篇国际商业和五篇经济文档预测为商业，将四篇环境文档和三篇宇宙文档预测为科学。图 7 的混淆矩阵显示，大型体育类别主要集中在对角线上，剩余错误集中于跨主题判断。这解释了词汇模型在准确率较高的同时，仍无法完全区分商业、政策和科学的部分相关主题。

稀疏基线的强表现说明，该语料中的具体主题词提供了大量分类信息，不保留词序也能取得较高分数。但这不等于词序对语言理解不重要：相近标签可能共享词汇，否定、关系或情感等任务也可能依赖词袋丢失的信息。课程实验的启示是先建立有竞争力的词汇基线，再讨论复杂模型究竟增加了哪些有效能力。

4 Task 2：100 维词向量与逻辑回归

本任务完成三组规定实验：预训练 GloVe 6B、AG News 文本训练的 Word2Vec，以及 NYT 训练文本训练的 Word2Vec。三组均使用 100 维词向量，对文档内有效词向量进行普通平均池化，再训练逻辑回归。

4.1 词向量来源与训练

预训练 GloVe 6B。 GloVe 利用全局词共现统计学习词向量 (Pennington et al., 2014)。实验使用公开的 `glove.6B.100d`，其训练语料为 Wikipedia 2014 和 Gigaword 5。原始词表包含 400,000 个词，加载时保留在分词后的 NYT 语料中出现的 70,193 个词条。这些预训练词向量在 NYT 分类过程中保持固定。

AG News 训练的 Word2Vec。 在 AG News 的 120,000 篇训练文本上训练 100 维 skip-gram 模型，通过局部词与上下文关系学习表示 (Mikolov et al., 2013)。标签不参与训练，所得词向量用于表示 NYT 文档并完成分类。

NYT 训练的 Word2Vec。 第二个 100 维 skip-gram 模型仅使用 NYT 的 10,405 篇训练文本。验证和测试文档不贡献词向量训练的词与上下文组合，所得向量采用相同文档分类流程。

两个 Word2Vec 模型均采用大小为 5 的上下文窗口、最低词频 2、5 个负样本、高频词采样阈值 10^{-3}、10 轮训练、单个 worker 和随机种子 42。AG News 与 NYT 的词表大小分别为 43,594 和 54,598。

带负采样的 skip-gram 使真实词与上下文的内积高于随机抽取的组合。对于目标词 w、真实上下文 c 和五个负样本 n_j，一次训练的目标贡献可表示为

$$\log \sigma(u_c^\top v_w) + \sum_{j=1}^{5} \log \sigma(-u_{n_j}^\top v_w), \tag{5}$$

其中 v 和 u 分别表示目标词向量与上下文向量。分类使用 Gensim 输出的目标词向量。两组实验共享训练参数，使训练语料来源成为两个 Word2Vec 表示之间的主要实验差异。

4.2 平均池化与文档分类

文档表示取已知词向量的平均值。令 K_d 为文档中具有词向量的词元出现构成的多重集合，则

$$e(d) = \frac{1}{|K_d|} \sum_{w \in K_d} e(w), \qquad e(d) \in \mathbb{R}^{100}. \tag{6}$$

重复出现的词重复计入，未知词同时从求和项和分母中排除。若文档中没有已知词，则使用零向量。平均池化不保留词序，将所有已知词压缩为 100 个数值，并通过相近的词向量在语义相关词之间共享信息。

分类前按 100 个特征维度分别标准化，均值与标准差仅从训练集计算，并应用于验证和测试向量。词向量在逻辑回归训练中保持固定，C 的搜索和验证选择规则与 Task 1 相同。图 1 展示从词向量来源到文档分类的完整流程。

4.3 结果与词覆盖率分析

表 2 汇总三组规定的词向量实验。平均词向量中，NYT Word2Vec 的 Macro-F1 最高，为 81.85%。它将每篇文档压缩为 100 维表示，仍接近使用 80,350 个词汇坐标的稀疏方法；GloVe 与 AG News Word2Vec 的分数较低。稠密表示能够在词之间共享语义信息，但平均池化无法为每个判别性词汇保留独立指示，也不能还原词序。

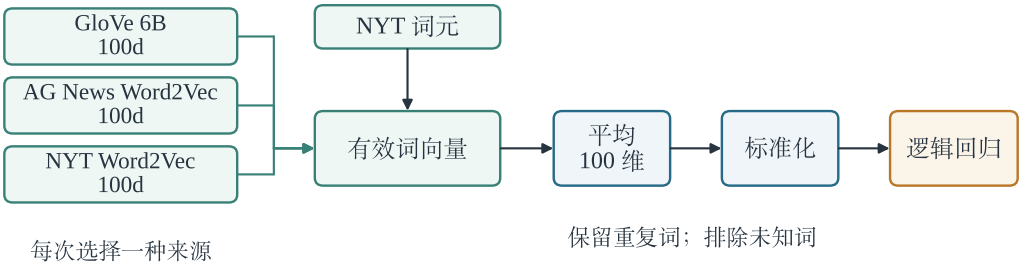


图 1: Task 2 的三种词向量来源与统一分类流程，每组实验使用一种来源。每次出现的有效词均计入平均，未知词从求和项和分母中排除；标准化及逻辑回归仅使用训练集拟合。

表 2: Task 2 的验证与测试结果（%）。三组均为 100 维词向量、普通平均池化和逻辑回归。

	验证集		测试集		
方法	准确率	Macro-F1	准确率	Macro-F1	选择
GloVe	92.92	83.72	91.71	79.38	$C = 0.1$
Word2Vec (AG News)	91.38	76.81	90.02	77.11	$C = 0.1$
Word2Vec (NYT)	93.77	83.33	92.63	81.85	$C = 1$

主实验的单次运行中，NYT Word2Vec 比 AG News Word2Vec 的 Macro-F1 高 4.74 个百分点。两个模型共用维度、训练参数、平均池化和分类器搜索设置。表 3 按测试词元出现次数统计覆盖率：NYT Word2Vec 为 99.08%，AG News Word2Vec 为 97.10%，GloVe 为 98.05%。

表 3: 词向量词表大小与 NYT 测试词元的出现次数加权覆盖率。GloVe 的词表大小为完整预训练版本的规模。三种来源均能为每篇测试文档找到至少一个有效词元。

词向量来源	词表大小	测试词覆盖率（%）	全零文档数
GloVe	400,000	98.05	0
Word2Vec (AG News)	43,594	97.10	0
Word2Vec (NYT)	54,598	99.08	0

NYT Word2Vec 的词表小于 GloVe 原始词表，却覆盖更多测试词元，因此词表规模不能单独描述词向量与任务的匹配程度。该结果与 NYT 训练语料提供更相关的词汇和上下文统计相一致。所有测试文档在三种词表下均包含已知词，不会退化为完全由未知词造成的零向量。

领域匹配不同于语料规模。 AG News 提供 120,000 篇训练文本，但仅由 10,405 篇 NYT 训练文档学习的词向量在 NYT 上更好。该现象与任务相关的共现统计及词汇匹配更有价值相一致，却不是严格的语料规模消融：两个来源还改变文档长度和主题构成，覆盖率也不能度量向量质量。一个词有向量，不代表该向量能区分细粒度主题。因此，这里支持的是领域内表示学习的价值，而非“小语料必然更好”或“Word2Vec 普遍优于大规模预训练资源”。

压缩在语义共享与词汇特异性之间取舍。 NYT 平均词向量比词频低 1.76 个 Macro-F1 百分点，但文档坐标仅为 100 维，而非 80,350 维，说明紧凑表示已保留不少主题信息。另一方面，关键判别词不同的文档仍可能具有相近均值，线性分类器无法恢复池化后丢失的区别。坐标减少不等于整个模型内存或部署成本同比下降，词向量表和表示准备仍有开销。后续池化对照检验的是能否通过更合理的权重缓解信息损失，而不是彻底消除这一瓶颈。

5 Task 3：BERT 预训练模型微调

本任务使用 `google-bert/bert-base-uncased` 完成端到端文本分类。规定设置为 `max_length=64`、严格训练 **3 epochs**，最终报告统一 NYT 测试集上的 Accuracy 与 Macro-F1。本节的结果对应这一规定配置；其他输入长度、类别加权和训练预算列于第 6 节。

5.1 模型架构与输入分词

BERT 通过预训练的双向 Transformer 提供上下文表示 (Devlin et al., 2019)。实验使用 `google-bert/bert-base-uncased`，编码器包含 12 层，隐藏维度为 768，每层有 12 个注意力头。其 uncased WordPiece 分词器直接处理原始文本。主实验输入包含特殊词元，总长度截断或补齐至 64，注意力掩码用于区分文本与补齐位置。

图 2 展示实际使用的 `BertForSequenceClassification`。最后一层的 `[CLS]` 表示先经过 768 维 Dense 层及 tanh 池化，再通过概率为 0.1 的 dropout 和 768 → 29 线性分类层输出 logits，以最大 logit 对应的类别作为预测。编码器、池化层与分类头使用交叉熵联合更新。编码器的每一层包含多头自注意力、残差连接、LayerNorm 和带 GELU 的前馈网络。

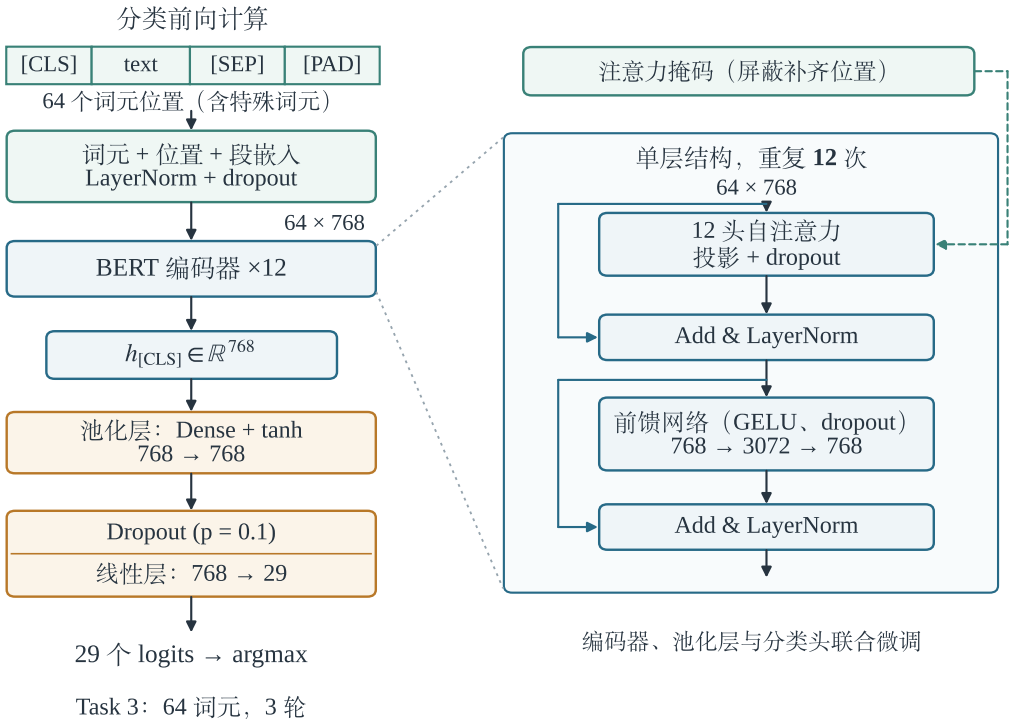


图 2: Task 3 的 BERT 分类架构。左侧为完整前向计算，右侧为重复 12 次的单层编码器；注意力掩码屏蔽补齐位置，浅灰点线标示结构展开。64 个位置包含特殊词元及补齐位置，最多保留 62 个文本 WordPiece。

5.2 微调设置与检查点选择

BERT 使用 AdamW，学习率为 2×10^{-5}，训练批大小为 32，评价批大小为 128，权重衰减为 0.01。偏置和 LayerNorm 权重不施加权重衰减。前 10% 的训练步数线性预热，随后学习率线性下降至零；梯度范数裁剪至 1.0。训练设备为 NVIDIA H100 80GB GPU，采用 bfloat16 自动混合精度。

训练总轮数固定为三轮，每轮结束后评价验证集，保存验证 Macro-F1 最高的检查点。选定检查点重新加载后直接评价测试集。本次选择第三轮；检查点选择规则与三轮训练预算同时保留。

5.3 规定配置的结果与学习曲线

表 4 给出 BERT 规定配置的结果。BERT 的测试准确率为 89.63%，Macro-F1 为 62.97%。图 3 显示，三轮训练损失持续下降，验证 Macro-F1 从 48.82% 上升至 61.03%，再上升至 63.37%；

验证准确率从 85.77% 上升至 89.08%。因此，最终选择第三轮检查点，验证指标在规定的停止位置仍在改善。

表 4: Task 3 规定配置的验证与测试结果（%）：BERT-base-uncased、输入长度 64、三轮训练、普通交叉熵。

	验证集		测试集		
方法	准确率	Macro-F1	准确率	Macro-F1	选择
BERT	89.08	63.37	89.63	62.97	第 3 轮

输入范围可能解释 BERT 与全文方法之间的部分差异。NYT 文档的正则分词长度中位数为 686 个词，而 BERT 的 64 个 WordPiece 位置扣除特殊词元后，最多保留 62 个文本词元。两种分词单位不同，但可见前缀明显短于典型文档。稀疏特征与平均词向量可汇总全文主题线索，BERT 只能利用保留前缀内的上下文关系。

七个零 F1 类别也构成类别加权探索的依据。BERT 在三轮微调中学习新的分类头，未加权的主实验设置给予常见类别更多训练样本。后续实验直接改变输入范围与损失目标，考察它们对分类能力的影响。

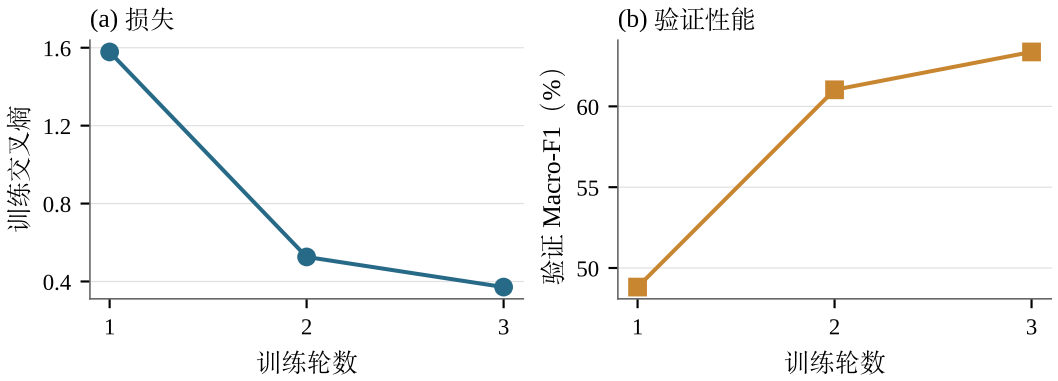


图 3: BERT 主实验三轮训练的平均交叉熵损失与验证 Macro-F1。训练损失按样本数加权平均，验证集选择第三轮检查点。

5.4 逐类表现与错误分析

表 7 对比常见体育类别、商业类别以及若干小类别。三个模型在棒球上均表现较好。BERT 在国际商业上超过两个稀疏模型，说明其较低的整体 Macro-F1 并非来自所有类别的一致下降。在堕胎和监控类别上，稀疏模型的 F1 为 100%，BERT 为零；这两个类别各只有三篇测试文档。

BERT 在 7 个类别上的测试 F1 为零：堕胎、宇宙、环境、联邦预算、枪支管制、移民和监控。这些类别的训练样本数介于 22 与 89 之间。常见类别在准确率中贡献更多文档，而这些类别中的每一个在 Macro-F1 中均占二十九分之一，零分会直接降低宏平均得分。图 6 展示七种方法的完整逐类分数。

保存的预测揭示了更明确的失败形式：BERT 在参考测试集上一次也没有输出上述七个标签。这些类别合计只有 38 篇文档，占测试集的 2.92%，却占 Macro-F1 类别项的 24.14%。这不是所有类别都略有下降，而是部分标签被压制。在全部 12 个低频类别上，主实验 BERT 的 Macro-F1 为 30.55%，词频为 76.48%。因此，少数类学习不足需要作为独立于输入截断的假设进行验证。

BERT 将宇宙和环境的各五篇测试文档全部预测为科学，体现了专门主题与相关宽泛主题之间的混淆。原始标签同时包含宽泛类别和细粒度类别，评价采用标签必须完全匹配的多类别标准。

具体错例不支持“全部由截断导致”的解释。 清洗后编号 `row_id=8195` 的文档真实标签为堕胎，关键词 “abortions” 已在 BERT 保留的 62 个文本 WordPiece 中出现；词频与 TF-IDF 均预测正确，BERT 却预测为平价医疗法案。`row_id=8527` 的真实标签为宇宙，保留前缀已出现 “NASA” 和 “Kepler”，BERT 仍预测为科学，而两个稀疏模型正确。这说明判别性词汇不总是位于被截去的后文。错例与少数类学习不足、细粒度决策边界不充分等解释相容，后续损失与预算对照进一步检验这些因素；仅凭关键词出现还不能作出因果归因。

模型之间也存在互补错误。`row_id=2143` 上，BERT 正确预测国际商业，两个稀疏模型均预测为商业。该类的 BERT 召回率为 84.38%，词频为 71.88%。整体分数较低并不排除有价值的类别特定能力。这些选取的实例用于提出和说明待检验机制，不代表全部错误的分布。

6 补充探索实验

在三项规定任务之外，补充实验考察输入长度、损失加权、池化、重复划分、训练预算和文本位置，共计 233 组独立配置。固定划分使用三个训练种子，重复划分使用五个划分种子；所有设置以验证 Macro-F1 选择模型。完整设计与参数见附录 C，逐配置结果见附录 D 和 E。

类别加权采用训练集频次倒数，$w_k = N_{\text{train}}/(29N_k)$。低频类 F1 对各划分中训练样本不超过 100 的类别取宏平均。跨划分统计先平均同一划分内的训练种子，再报告五个划分均值的均值与样本标准差；固定划分的误差棒表示三个训练种子的样本标准差。

6.1 输入长度与类别加权

在相同三轮训练预算下，更长的输入改善了 BERT 的表现（表 5、图 4）。普通损失的 Macro-F1 从 64 词元时的 $65.60 \pm 3.27\%$ 提高到 256 词元时的 $76.62 \pm 1.74\%$，平均提高 11.03 个百分点。三个配对种子均有提升，增幅为 7.92 至 13.45 个百分点。语料存在明显截断：WordPiece 长度中位数为 890，99.95% 的文档超过 62 个文本词元的预算，该预算保留的正则分词长度中位数为 49 个词。

表 5: BERT 输入长度与损失对照。分数为百分比，报告三个训练种子的均值与样本标准差。低频类 F1 对训练样本不超过 100 的类别取宏平均，每组均完整训练三轮。

长度	损失	准确率	Macro-F1	低频类 F1
64	普通	89.96 ± 0.45	65.60 ± 3.27	36.24 ± 7.11
64	加权	89.68 ± 0.19	79.53 ± 1.46	72.85 ± 2.85
128	普通	92.11 ± 0.38	72.38 ± 2.89	50.50 ± 7.72
128	加权	91.81 ± 0.12	82.39 ± 0.27	75.86 ± 0.76
256	普通	93.75 ± 0.18	76.62 ± 1.74	58.31 ± 4.26
256	加权	92.93 ± 0.08	83.26 ± 0.47	76.67 ± 1.25
512	普通	94.19 ± 0.23	80.15 ± 1.74	66.43 ± 4.73
512	加权	93.45 ± 0.12	84.45 ± 0.59	78.43 ± 1.42

类别加权主要改善低频主题的识别。64 词元时，平均低频类 F1 从 36.24% 提高至 72.85%；256 词元时，从 58.31% 提高至 76.67%。64–256 长度的各加权运行在全部 29 个类别上均有非零 F1。256 词元时，加权使准确率下降 0.82 个百分点，Macro-F1 提高 6.63 个百分点。加权 BERT 在 256 和 512 长度上分别达到 $83.26 \pm 0.47\%$ 和 $84.45 \pm 0.59\%$。512 词元仍截断 81.16% 的文档，平均保留 64.45% 的 WordPiece；更长输入增加可见证据，同时仍受前缀范围约束。

类别加权改变的是学习目标。 暂不考虑每个批次内按权重和归一化损失，$N_k w_k = N_{\text{train}}/29$ 使各类训练样本的总权重相同，目的是让小类别错误在优化中得到更多重视，而非增加可见文本。固定为 64 词元时，加权使平均 Macro-F1 提高 13.93 个百分点，低频 F1 从 36.24% 提高至 72.85%，准确率仅下降 0.28 个百分点。这直接支持类别不均衡是独立于截断的限制。加权交叉熵仍是替代目标，并不直接优化不可按样本分解的 Macro-F1，也不保证每类精确率都改善。

长度与加权的提升不能当作独立效果相加。加权优势从 64 词元时的 13.93 个百分点缩小到 256 时的 6.63；增大输入长度使普通损失提高 11.03 个百分点，加权损失则提高 3.73。两个

干预都帮助小类别，在当前三轮协议下存在收益重叠。长输入还会增加注意力计算和显存需求，因此更合理的结论是联合考察文本范围与学习目标，而非默认最长输入一定是最合适的选择。

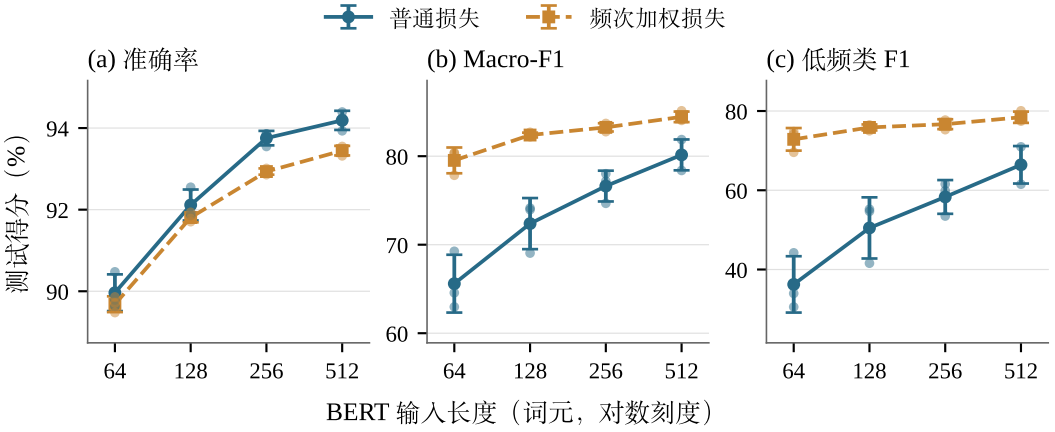


图 4: BERT 输入长度与损失对照：(a) 准确率，(b) Macro-F1，(c) 低频类 F1。浅色小点表示单次运行，折线与误差棒表示三个种子的均值与样本标准差。各输入长度下，加权均改善低频类别识别。

6.2 稀疏模型的相同文本范围对照

表 12 在每种稀疏表示内考察可见文本范围的影响。64 词元预算下，TF-IDF 与词频的 Macro-F1 分别为 73.47% 和 71.31%，全文分数分别为 82.85% 和 83.61%。词频与 TF-IDF 随预算增加持续改善；二值词袋在 128 时下降，再于 256 时改善。训练前缀覆盖与 BERT 保留文本相同的字符区间，因此能够展示后续主题信息在各分类流程内的作用。

64 词元区间下，TF-IDF 的 73.47% Macro-F1 仍超过普通 BERT 的三种子均值 65.60%，说明可见文本少只能解释主实验 BERT 差距的一部分。同样长度的加权 BERT 达到 79.53%，又说明短前缀中仍能学习有效区别。不过，后一比较同时改变了损失，不能只归因于架构。匹配文本范围是重要控制，公平的表示对照还应明确学习目标、验证选择与优化预算。

6.3 池化方式与 Word2Vec 训练波动

IDF 加权改善了三种词向量来源的文档表示（附录 D 的表 13）。GloVe、AG News Word2Vec 与 NYT Word2Vec 的平均 Macro-F1 分别提高 0.54、1.36 和 1.00 个百分点。该池化保留重复词元，同时降低常见词的相对贡献。三个种子的平均池化对照中，NYT Word2Vec 比 AG News Word2Vec 高 3.56 个百分点。每组池化对照共用词向量、维度和分类器参数搜索。图 8 汇总相同文本前缀与池化两类对照。

IDF 池化针对的是表示瓶颈：普通平均中大量通用词可能稀释主题特定词，加权在不重新训练词向量、不增加文档维度的情况下调整它们的相对贡献。效果较小，且并非每个种子都提高：NYT 种子 42 的 Macro-F1 改变 −0.01 个百分点，种子 43、44 分别提高 1.71、1.30；AG News 的三个种子均提高。因此，更高均值支持尝试该池化，但三次运行不足以证明普遍改善或统计显著。加权平均仍丢失词序，也仍可能稀释少量决定性词汇。

6.4 跨划分排名与统一损失对照

表 18 在五个划分上比较全文传统模型与长上下文 BERT。加权 BERT-512 的 Macro-F1 为 84.22 ± 0.87%，普通词频为 81.68%，加权词频为 83.35%；加权 BERT-512 相对二者的配对平均差值分别为 +2.53 和 +0.87 个百分点。图 10 展示每个划分的均值与配对差值。

加权 TF-IDF 的 Macro-F1 为 84.49 ± 2.75%；加权 BERT-512 相对它的配对平均差值为 -0.27 个百分点，划分波动更小。因此，当词汇分类器采用相同类别加权规则时，表示排名也随之变化。

图 9 对各分类器统一采用类别频次倒数加权。512 词元下，加权使 BERT 的 Macro-F1 改变 4.10 个百分点，准确率改变 -0.92 个百分点。NYT Word2Vec-IDF 的 Macro-F1 则在加权后从 81.07% 降至 80.43%。图 13 展示逐类变化，参考划分中的军事类别在两个长度下均因加权而降低 F1。加权 BERT 从 256 增至 512 词元，在划分均值上增加 0.77 个百分点。表 25 列出重复划分下的稀疏前缀对照。

配对结果进一步界定了排名结论。加权 BERT-512 在全部五个划分上超过普通词频，差值为 +0.84 至 +4.03 个百分点；但相对加权 TF-IDF 仅两个划分领先、三个落后，配对差值为 -0.27 ± 2.03 个百分点（均值与样本标准差）。这两种方法中没有一个在所有观察划分上都领先，标准差也不是置信区间。因此，“BERT 普遍胜过词汇基线”的说法会依赖是否允许基线采用相同加权规则。

类别加权也不是通用补救措施。NYT Word2Vec-IDF 的平均 Macro-F1 反而下降，可能因为移动决策边界无法分离已经重叠的平均表示，并引入更多假阳性。但这是解释假设而非已诊断的原因，需要进一步查看逐类混淆变化及特征的类内、类间距离。现有反例已经足以否定“频次倒数加权一定提高 Macro-F1”的笼统规则。

6.5 优化预算与主题线索位置

保持 64 词元前缀不变，十轮普通损失 BERT 的 Macro-F1 为 79.80%，改变 +14.20 个百分点。512 长度下，普通损失为 86.38%，加权为 85.72%；十轮的 256 长度也由普通损失领先，与三轮时的损失排名相反。表 26 和图 11 给出选定检查点与验证轨迹。固定的加权 BERT-256 预算下，完整头部为 83.26%，头尾组合为 81.57%，尾部为 76.22%（表 27、图 12），参考划分中完整前缀在这些区间里表现最好。

训练时间会改变对加权的理解。 保持 64 词元不变，十轮普通损失使 Macro-F1 提高 14.20 个百分点，低频 F1 从 36.24% 提高至 72.81%。没有增加后文，说明截断不可能是唯一瓶颈。类别加权可能帮助小类更早学习，而更多优化使普通目标也能恢复相当一部分能力。这与分数变化相一致，并不等于直接测量了各类梯度动态。十轮实验同时改变预热与衰减的时间跨度，不能把增益全部归因于单纯增加轮数。

十轮时的损失排名反转只描述均值，不代表已证实统计优越：256 和 512 长度下，普通损失仅领先 1.02 和 0.66 个百分点，均只有三个种子。加权 BERT-256 的三个种子均选择第四轮，虽实际完整训练十轮；普通损失选择第六、九、四轮。因此，“允许更长预算”不同于“使用最后一个检查点”。应监控对少数类敏感的验证指标，而不应简单认为轮数越多或持续加权必然更好。

主题证据的位置与数量同样重要。 头部比尾部高 7.03 个 Macro-F1 百分点，将一半头部替换为尾部后，均值反而降低 1.68 个百分点。这与新闻导语集中提供主题线索相容，却不说明结尾没有价值：仅尾部仍达到 76.22%，且头尾对照同时移除了部分导语并改变文本连续性。后续可通过滑动窗口或层次聚合检验能否利用后文，同时避免上述取舍。

7 课程探索的启示

本次结果不支持“表示越复杂就必然越好”的简单顺序。全文词汇特征适合当前新闻任务，领域内平均词向量以紧凑表示取得接近的效果，而 BERT 的表面弱势会随着输入、目标和预算的控制而改变。探索作业的价值在于把异常分数拆成可检验的问题：前缀对照检验能否读到证据，池化对照检验证据怎样被压缩，损失与预算对照检验各类别怎样被学到。没有单个干预可以解释全部差异。

对类似课程实验，合理流程是先建立简单基线，查看逐类精确率和召回率，再逐项改变明确的限制条件。Accuracy 与 Macro-F1 应结合类别样本数及配对预测解释。稳定、低开销的词汇流程可以作为起点，但当前 CPU/GPU 耗时并非统一硬件下的成本比较。模型选择应依据目标指标与计算条件，而非仅依据某次运行的排名。

后续假设，而非已完成的新实验。 下一步可分离 IDF 与 L2 归一化的效果，为各模型匹配学习目标和文本预算，并比较连续窗口与文档级聚合。分层划分及锁定的最终测试集有助于考察小类别，同时减少根据测试结果反复调整的影响。将长预算对照扩展到多个划分，可检验损失排名反转能否推广。这些属于待验证方向，本报告不声称已运行这些实验。

8 局限性

五个划分复用同一语料，包含相互重叠的文档；其标准差描述划分敏感性，并非独立总体的置信区间。参考划分的部分类别只有三至五篇测试文档，少量预测变化即可明显影响 F1。划分 43 的测试集中没有宇宙类别文档，固定 29 类的宏平均仍包含该类，其 F1 为零。低频类名单分别由各训练划分确定。拓展实验在查看主实验后设计，其测试结果属于探索性分析。公开标签同时包含宽泛主题与专门主题，评价采用平面多类别标准。

BERT 最多读取 512 个词元，十轮与位置实验使用一个划分。头尾拼接同时改变局部文本连续性；字符范围相同时，各表示仍采用自己的分词与拟合方式。Word2Vec 来源对照同时改变语料内容、词覆盖率与文档长度分布。实际耗时受表示准备、硬件和任务并行执行影响。

9 结论

Task 1 中，TF-IDF 的测试准确率最高（94.01%），词频的 Macro-F1 最高（83.61%）。Task 2 中，NYT Word2Vec 以 81.85% Macro-F1 领先三种平均词向量。Task 3 按 64 词元、三轮训练完成 BERT 微调，取得 89.63% 准确率与 62.97% Macro-F1。补充实验表明，文本范围、类别加权和训练预算会改变方法排名；参考划分的十轮预算下，普通损失在 256/512 词元输入时的平均 Macro-F1 超过类别加权，但这不代表跨语料的显著优势。

本次探索的核心是先解释排名，再讨论推广。BERT 的少数标签缺失不能仅归因于后文不可见，不同目标与预算下的恢复也不否定词汇基线的价值。有用的结论应同时包含指标、逐类错误、控制对照及明确的不确定性。后续实验应验证这些解释，而不只是寻找更高的测试分数。

参考文献

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pp. 4171–4186, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL https://aclanthology.org/N19-1423/.

Yu Meng, Jiaming Shen, Chao Zhang, and Jiawei Han. Weakly-supervised hierarchical text classification. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pp. 6826–6833, 2019. doi: 10.1609/aaai.v33i01.33016826. URL https://doi.org/10.1609/aaai.v33i01.33016826.

Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S Corrado, and Jeff Dean. Distributed representations of words and phrases and their compositionality. In *Advances in Neural Information Processing Systems*, volume 26. Curran Associates, Inc., 2013. URL https://proceedings.neurips.cc/paper_files/paper/2013/file/9aa42b31882ec039965f3c4923ce901b-Paper.pdf.

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12(85): 2825–2830, 2011. URL http://jmlr.org/papers/v12/pedregosa11a.html.

Jeffrey Pennington, Richard Socher, and Christopher Manning. GloVe: Global vectors for word representation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1532–1543, Doha, Qatar, October 2014. Association for Computational Linguistics. doi: 10.3115/v1/D14-1162. URL https://aclanthology.org/D14-1162/.

Xiang Zhang, Junbo Zhao, and Yann LeCun. Character-level convolutional networks for text classification. In *Advances in Neural Information Processing Systems*, volume 28. Curran Associates, Inc., 2015. URL https://proceedings.neurips.cc/paper_files/paper/2015/file/250cf8b51c773f3f8dc8b4be867a9a02-Paper.pdf.

A 类别分布与完整结果

A.1 七种方法的完整汇总

表 6: 三个 Task 的七种方法在统一划分上的验证与测试性能 (%)。选择依据为验证 Macro-F1，粗体表示最高测试分数。除 BERT 外均使用逻辑回归。

	验证集		测试集		
方法	准确率	Macro-F1	准确率	Macro-F1	选择
二值词袋	94.38	84.86	92.47	80.47	$C = 10$
词频	93.69	84.02	93.63	**83.61**	$C = 1$
TF-IDF	95.00	84.86	**94.01**	82.85	$C = 10$
GloVe	92.92	83.72	91.71	79.38	$C = 0.1$
Word2Vec (AG News)	91.38	76.81	90.02	77.11	$C = 0.1$
Word2Vec (NYT)	93.77	83.33	92.63	81.85	$C = 1$
BERT	89.08	63.37	89.63	62.97	第 3 轮

A.2 类别分布与逐类结果

表 7: 主实验中部分类别的样本数量与测试 F1。

	文档数		测试 F1（%）		
类别	训练	测试	词频	TF-IDF	BERT
棒球	1795	212	99.05	99.05	97.39
国际商业	384	32	71.88	72.13	80.60
堕胎	22	3	100.00	100.00	0.00
宇宙	30	5	44.44	40.00	0.00
环境	40	5	28.57	0.00	0.00
监控	40	3	100.00	100.00	0.00

表 8 给出统一划分的类别数量。编号按照原始标签的字母顺序排列，与实现及图 7 一致。中文名称用于展示，原始标签栏以空格显示原标签中的下划线。

表 8: 移除标签冲突与相同文本重复记录后的 NYT 类别分布。

编号	类别	原始标签	训练	验证	测试
1	堕胎	abortion	22	3	3
2	棒球	baseball	1795	208	212
3	篮球	basketball	792	95	110
4	商业	business	351	38	51
5	宇宙	cosmos	30	6	5
6	舞蹈	dance	87	8	13
7	经济	economy	209	29	32
8	能源企业	energy companies	115	14	9
9	环境	environment	40	4	5
10	联邦预算	federal budget	89	14	6
11	美式橄榄球	football	1226	146	160
12	同性恋权利	gay rights	68	9	7
13	高尔夫	golf	799	114	114
14	枪支管制	gun control	46	5	7
15	冰球	hockey	513	66	75
16	移民	immigration	44	5	9
17	国际商业	international business	384	42	32
18	执法	law enforcement	331	41	41
19	军事	military	53	5	3
20	电影	movies	265	29	34
21	音乐	music	326	51	36
22	政治	politics	372	44	42
23	科学	science	336	49	43
24	足球	soccer	1081	133	141
25	股票与债券	stocks and bonds	91	9	10
26	监控	surveillance	40	6	3
27	电视	television	159	24	11
28	网球	tennis	652	88	77
29	平价医疗法案	the affordable care act	89	15	11
	合计		10,405	1,300	1,302

表 9 列出全部测试类别 F1。AG 与 NYT 分别表示两种 Word2Vec 训练语料；二值词袋、词频与 TF-IDF 共用 NYT 训练词表。图 6 以热图展示同一组指标。

表 9: 七种方法的完整逐类测试 F1，单位为百分比。

编号	类别	二值	词频	TF-IDF	GloVe	AG	NYT	BERT
1	堕胎	80.00	100.00	100.00	66.67	80.00	100.00	0.00
2	棒球	98.34	99.05	99.05	98.57	97.85	98.57	97.39
3	篮球	98.62	99.08	99.54	95.81	94.84	97.70	91.67
4	商业	67.33	75.00	77.36	75.73	68.04	77.23	76.47
5	宇宙	57.14	44.44	40.00	36.36	40.00	44.44	0.00
6	舞蹈	96.00	96.00	96.00	92.31	86.96	96.00	96.00
7	经济	69.09	77.19	77.97	79.31	73.68	79.31	74.29
8	能源企业	60.00	57.14	60.87	50.00	40.00	42.11	57.14
9	环境	0.00	28.57	0.00	33.33	57.14	57.14	0.00
10	联邦预算	57.14	57.14	61.54	50.00	57.14	37.50	0.00
11	美式橄榄球	98.76	98.77	99.38	96.64	96.32	97.55	92.83
12	同性恋权利	76.92	72.73	83.33	76.92	83.33	72.73	66.67
13	高尔夫	98.67	99.12	100.00	98.21	98.23	100.00	97.37
14	枪支管制	72.73	92.31	92.31	92.31	92.31	92.31	0.00
15	冰球	99.34	100.00	100.00	100.00	98.68	100.00	99.33
16	移民	80.00	82.35	82.35	82.35	66.67	70.59	0.00
17	国际商业	71.88	71.88	72.13	72.73	69.44	70.59	80.60
18	执法	83.72	87.50	86.42	81.01	79.01	82.35	69.57
19	军事	80.00	85.71	80.00	85.71	75.00	85.71	60.00
20	电影	95.77	97.14	94.44	94.44	94.29	89.55	89.86
21	音乐	93.33	95.77	100.00	95.77	87.67	93.15	94.12
22	政治	80.90	82.35	83.15	72.73	69.66	75.29	78.26
23	科学	84.54	83.87	83.52	83.15	83.52	87.91	81.63
24	足球	97.90	98.59	98.59	97.18	97.14	97.87	98.59
25	股票与债券	76.19	88.89	82.35	84.21	72.73	88.89	82.35
26	监控	100.00	100.00	100.00	85.71	75.00	85.71	0.00
27	电视	90.00	85.71	85.71	76.19	64.00	83.33	81.82
28	网球	99.35	98.72	100.00	98.72	97.44	100.00	98.72
29	平价医疗法案	70.00	69.57	66.67	50.00	40.00	70.00	61.54

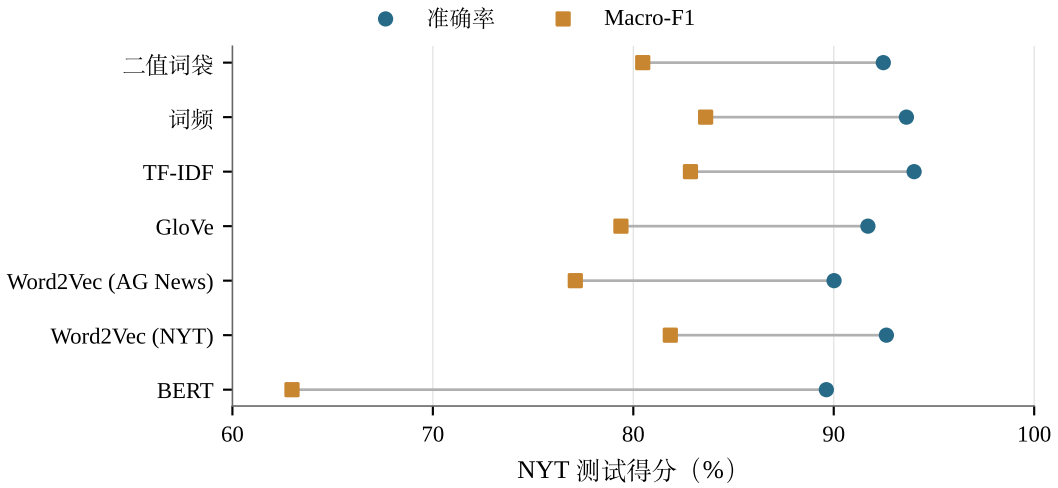


图 5: 七种方法在主实验中的准确率与 Macro-F1。连线展示按文档计数的准确率与按类别等权平均的 F1 之间的差距。精确分数与模型选择见表 6。

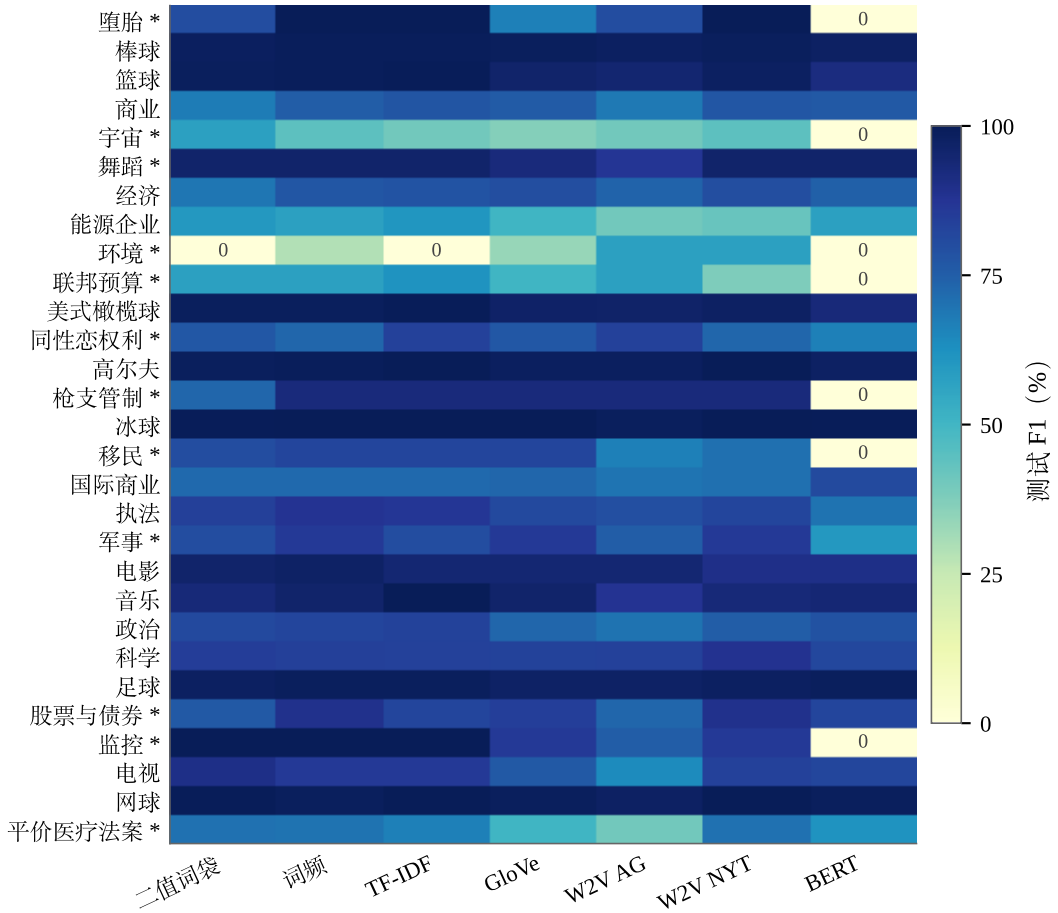


图 6: 主实验的逐类测试 F1。星号表示训练文档数不超过 100 的类别，零 F1 单元格标出数值；W2V AG/NYT 表示 Word2Vec 的训练来源。颜色越深，F1 越高。

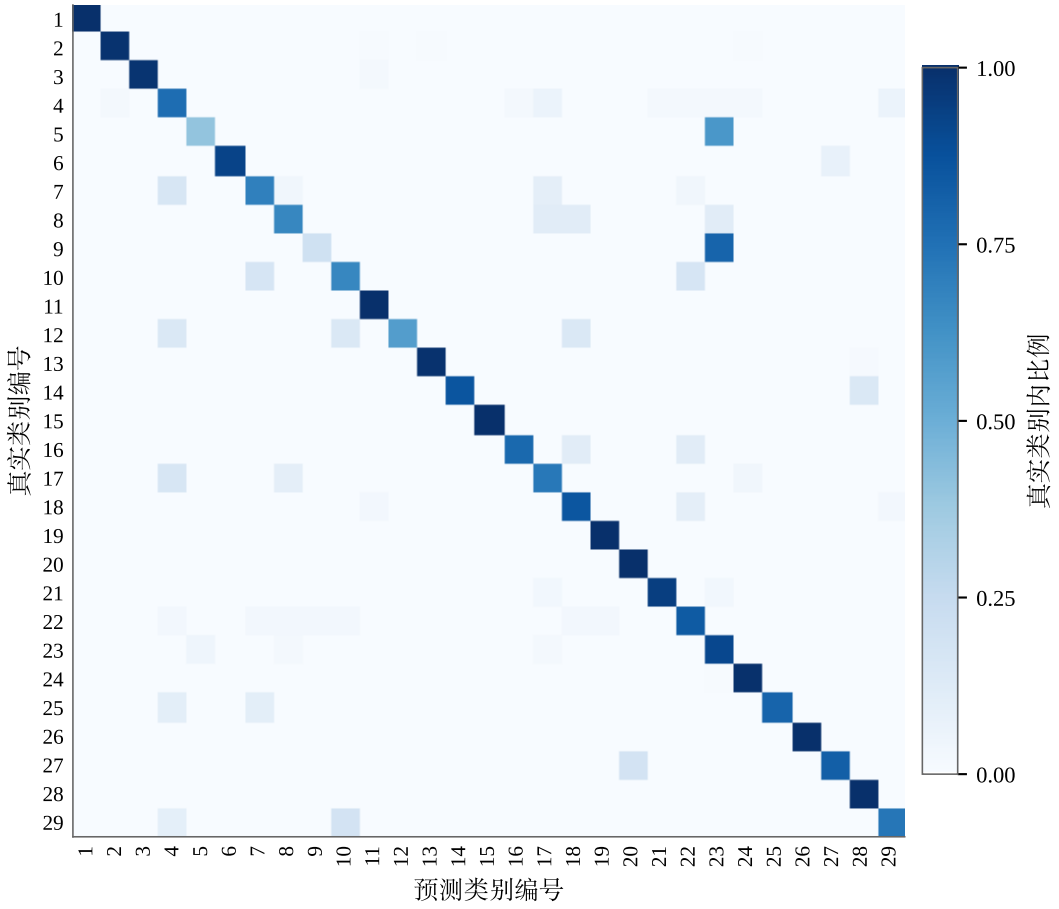


图 7: 词频方法的测试混淆矩阵，按真实类别逐行归一化。行表示真实标签，列表示预测标签，每行之和为一。类别编号对应表 8。

B 训练记录与复现说明

表 10 给出保存的 BERT 训练记录，表 11 给出各方法内部测得的耗时。传统方法耗时包含表示准备、三组逻辑回归参数搜索、评价与输出保存；Word2Vec 还包含词向量训练。BERT 耗时包含模型加载、微调、检查点保存与重新加载，以及评价。表中的 768 维表示 BERT 上下文隐藏维度，并非用于逻辑回归的固定特征矩阵。

表 10: BERT 训练损失与验证指标。

轮数	训练损失	验证准确率（%）	验证 Macro-F1（%）
1	1.5785	85.77	48.82
2	0.5259	88.46	61.03
3	0.3713	89.08	63.37

表 11: 实际耗时与表示维度。CPU 与 GPU 使用不同硬件，各方法包含的准备操作也不同。

方法	表示维度	耗时（秒）	设备
二值词袋	80350	60.16	CPU
词频	80350	383.80	CPU
TF-IDF	80350	64.84	CPU
GloVe	100	20.29	CPU
Word2Vec (AG News)	100	192.22	CPU
Word2Vec (NYT)	100	277.55	CPU
BERT	768	70.11	H100 GPU

B.1 运行命令与实验记录

homework1/README.md 给出环境安装方法。从仓库根目录进入 homework1/ 后，以下命令可下载资源、运行实验并根据预测重新计算指标。仓库提供最终 PDF，不包含报告生成工具：

```
cd homework1
python scripts/prepare_assets.py
PYTHONHASHSEED=42 python run_experiments.py \
  --bert-model data/bert-base-uncased
PYTHONHASHSEED=42 python -m scripts.run_explorations
PYTHONHASHSEED=42 python -m scripts.run_scaling
python scripts/verify_results.py --results outputs/main \
  --explorations outputs/explorations
python scripts/verify_scaling.py
```

运行实验后会生成下述输出记录；下载资源、模型权重和运行记录不放入 Git。划分行号保存于 outputs/main/splits.json。每种方法的输出目录保存测试预测、混淆矩阵、逐类指标和验证选择记录。BERT 的三轮训练历史位于 outputs/main/bert/training_history.json，库版本和运行参数与汇总结果共同保存。

B.2 公开资源地址

下载程序使用以下公开资源：

- NYT：https://github.com/yumeng5/WeSHClass/tree/master/nyt。
- AG News：https://huggingface.co/datasets/fancyzhx/ag_news。
- GloVe：https://nlp.stanford.edu/projects/glove/。
- BERT：https://huggingface.co/google-bert/bert-base-uncased。

GloVe 通过 Gensim 的 glove-wiki-gigaword-100 镜像下载，对应相同的 Wikipedia 2014 与 Gigaword 5 词向量。程序在加载前移除 word2vec 格式的首行。

C 补充实验的完整设置

C.1 拓展实验设计

固定划分的上下文实验采用 64、128、256、512 四种输入长度，损失为普通交叉熵或类别频次倒数加权交叉熵，每种设置运行训练种子 42、43、44。24 组配置均保留三轮训练、批大小 32、相同优化参数与验证集选择规则。类别 k 的权重为 $w_k = N_{\text{train}}/(29N_k)$，其中 N_k 为其训练样本数；每个批次的加权交叉熵按样本权重之和归一化。

相同文本范围的对照使用 BERT 前 $L-2$ 个 WordPiece 覆盖的原始字符区间，三种 BoW 分别在对应训练前缀上拟合词表与 IDF。平均词向量增加 TF-IDF 加权池化：

$$e_{\text{idf}}(d) = \frac{\sum_{w \in K_d} \text{idf}(w) e(w)}{\sum_{w \in K_d} \text{idf}(w)}. \tag{7}$$

K_d 保留重复词元，平滑 IDF 仅使用 NYT 训练文档频次。具有词向量但未在训练文档出现的词，文档频次设为零。两种 Word2Vec 来源均运行三个种子，同一词向量模型用于两种池化；GloVe 保持固定。低频类 F1 对训练样本不超过 100 的类别取宏平均，参考划分中共有 12 个此类类别。

C.2 重复划分与训练预算

划分种子 42–46 分别产生随机打乱的 80/10/10 划分，清洗方式相同。每个划分中，BERT 交叉比较 256/512 两种长度、两种损失和三个训练种子；三种稀疏方法交叉比较全文、匹配的 256/512 词元前缀以及两种损失。NYT Word2Vec 采用三个训练种子、IDF 池化和两种逻辑回归损失。每个划分单独拟合词表、IDF、标准化参数、NYT 词向量、类别权重及验证集选择。稀疏分类器使用确定性的求解器，每个设置拟合一次。

划分 42 另比较 64、256、512 长度、两种损失与十轮训练预算。学习率调度覆盖指定训练轮数，检查点按全部已完成轮次的验证 Macro-F1 选择。位置实验采用加权 BERT-256，分别保留前 254 个 WordPiece、后 254 个，或拼接前后各 127 个；较短文档保留完整文本。两项对照均使用三个训练种子。

重复划分实验包包含 204 组配置，其中 15 组复用相同的固定划分设置。完整研究共有 233 组独立配置。跨划分汇总先在每个划分内平均训练种子，再报告五个划分均值的均值与样本标准差；固定划分的误差棒则表示三个训练种子的波动。

D 拓展配置与逐类结果

表 13 汇总池化对照。表 14–16 列出 41 组拓展配置，包含从主实验复用的四组参照。测试分数均由保存的预测重新计算。训练种子改变初始化、采样与训练顺序，数据行号保持固定；类别权重与 IDF 均仅使用训练集。逐组记录和多种子汇总保存于 `outputs/explorations/`。

表 12: 划分 42 的稀疏模型全文与匹配前缀对照。测试分数为百分比，各表示单独拟合训练词表并在验证集选择 C。

	二值词袋		词频		TF-IDF	
范围	准确率	Macro-F1	准确率	Macro-F1	准确率	Macro-F1
全文	92.47	80.47	93.63	83.61	94.01	82.85
64	84.79	71.43	84.95	71.31	86.64	73.47
128	87.25	67.59	88.86	73.87	90.78	76.36
256	91.17	73.59	91.01	77.39	93.01	79.54

表 13: NYT 上的词向量池化对照，分数为百分比。Word2Vec 使用三个配对训练种子，报告均值与样本标准差；GloVe 是固定词向量的一次实验。

		平均池化		TF-IDF 加权	
词向量来源	种子数	准确率	Macro-F1	准确率	Macro-F1
GloVe	1	91.71	79.38	91.86	79.92
Word2Vec (AG News)	3	90.19 ± 0.16	77.09 ± 0.94	90.63 ± 0.28	78.45 ± 0.04
Word2Vec (NYT)	3	92.40 ± 0.20	80.65 ± 1.10	92.73 ± 0.59	81.65 ± 0.59

表 14: 各 BERT 训练种子的结果。除低频 F1 外，F1 列均为 Macro-F1；零 F1 列统计测试 F1 为零的类别数。分数单位为百分比。

长度	损失	种子	选择轮数	验证 F1	测试准确率	测试 F1	低频 F1	零 F1 类
64	普通	42	3	63.37	89.63	62.97	30.55	7
64	普通	43	3	65.92	90.48	69.26	44.21	4
64	普通	44	3	65.91	89.78	64.57	33.97	6
64	加权	42	3	80.57	89.86	80.40	74.17	0
64	加权	43	3	78.74	89.71	80.33	74.81	0
64	加权	44	3	80.05	89.48	77.84	69.58	0
128	普通	42	3	72.60	91.94	69.05	41.59	5
128	普通	43	3	71.36	92.55	74.14	54.68	3
128	普通	44	3	75.61	91.86	73.95	55.22	3
128	加权	42	3	82.49	91.71	82.20	75.02	0
128	加权	43	3	84.23	91.78	82.28	76.07	0
128	加权	44	3	83.49	91.94	82.70	76.49	0
256	普通	42	3	73.07	93.55	74.67	53.49	4
256	普通	43	3	76.78	93.86	77.18	59.89	3
256	普通	44	3	76.60	93.86	78.02	61.56	3
256	加权	42	3	85.09	92.86	83.70	77.71	0
256	加权	43	3	86.21	92.93	83.30	77.02	0
256	加权	44	3	87.27	93.01	82.77	75.29	0

表 15: 前缀词表大小、验证集参数选择与测试结果。F1 表示 Macro-F1，分数为百分比。

表示	长度	词表大小	C	验证 F1	测试准确率	测试 F1
二值词袋	64	28,353	10	68.47	84.79	71.43
二值词袋	128	38,001	10	76.27	87.25	67.59
二值词袋	256	49,632	1	80.87	91.17	73.59
词频	64	28,353	10	71.30	84.95	71.31
词频	128	38,001	10	79.26	88.86	73.87
词频	256	49,632	1	81.37	91.01	77.39
TF-IDF	64	28,353	10	69.65	86.64	73.47
TF-IDF	128	38,001	10	76.57	90.78	76.36
TF-IDF	256	49,632	10	80.02	93.01	79.54

表 16: 各词向量池化配置的逐种子结果。F1 表示 Macro-F1，分数为百分比。

来源	池化	种子	C	验证 F1	测试准确率	测试 F1
GloVe	平均	42	0.1	83.72	91.71	79.38
GloVe	加权	42	0.1	82.18	91.86	79.92
Word2Vec (AG News)	平均	42	0.1	76.81	90.02	77.11
Word2Vec (AG News)	加权	42	0.1	77.89	90.32	78.49
Word2Vec (AG News)	平均	43	0.1	75.91	90.25	76.14
Word2Vec (AG News)	加权	43	0.1	77.91	90.86	78.41
Word2Vec (AG News)	平均	44	0.1	75.04	90.32	78.01
Word2Vec (AG News)	加权	44	0.1	77.11	90.71	78.45
Word2Vec (NYT)	平均	42	1	83.33	92.63	81.85
Word2Vec (NYT)	加权	42	0.1	83.53	92.86	81.84
Word2Vec (NYT)	平均	43	1	82.51	92.24	80.42
Word2Vec (NYT)	加权	43	1	82.53	93.24	82.12
Word2Vec (NYT)	平均	44	1	83.39	92.32	79.68
Word2Vec (NYT)	加权	44	1	83.24	92.09	80.98

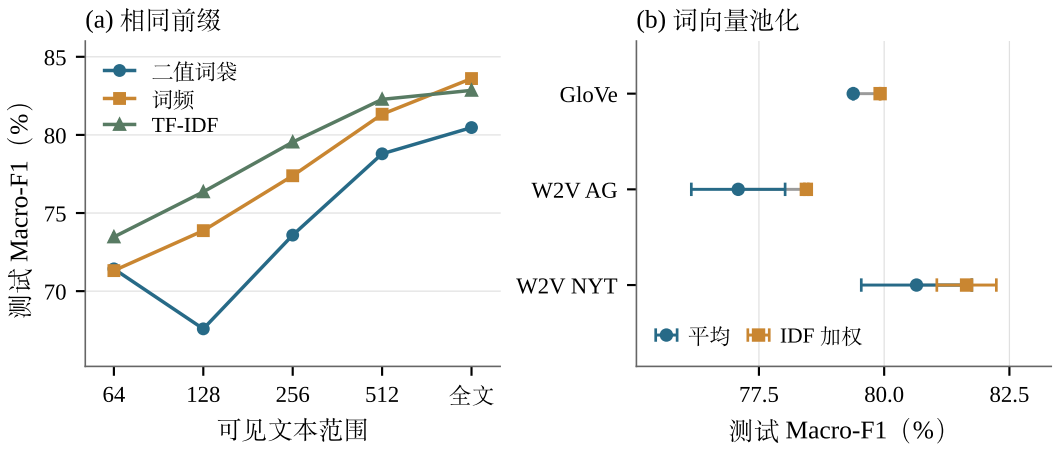


图 8: 固定划分的可见文本与池化对照。(a) 稀疏模型在相同前缀和全文上的 Macro-F1。(b) 平均与 IDF 加权池化；Word2Vec 误差棒为三个训练种子的样本标准差，GloVe 使用固定词向量。

表 17: BERT 的逐类测试 F1，对三个训练种子取平均。加权表示类别频次倒数交叉熵，分数为百分比；类别编号与表 8 一致。

		64		128		256	
编号	类别	普通	加权	普通	加权	普通	加权
1	堕胎	0.00	100.00	0.00	100.00	0.00	100.00
2	棒球	97.08	97.06	98.49	98.33	99.29	98.98
3	篮球	91.81	91.86	96.47	95.87	98.15	97.87
4	商业	77.24	71.04	74.84	70.68	82.74	75.74
5	宇宙	0.00	43.25	0.00	39.18	0.00	39.18
6	舞蹈	90.33	90.67	100.00	100.00	96.00	98.77
7	经济	75.64	77.37	77.79	79.31	81.14	79.98
8	能源企业	57.54	55.34	56.44	57.56	56.79	55.28
9	环境	0.00	62.42	0.00	62.22	0.00	55.00
10	联邦预算	0.00	47.37	44.44	67.94	38.18	54.05
11	美式橄榄球	92.98	92.85	96.67	96.44	98.44	98.22
12	同性恋权利	66.67	83.08	68.69	71.67	73.50	89.74
13	高尔夫	97.52	96.78	98.69	98.54	99.56	99.56
14	枪支管制	20.00	71.43	73.42	80.00	87.18	80.24
15	冰球	99.33	98.23	99.34	99.34	100.00	100.00
16	移民	6.67	75.05	46.55	80.00	69.64	86.11
17	国际商业	80.36	75.00	78.98	74.12	78.32	76.45
18	执法	71.53	74.50	77.38	79.11	84.77	83.57
19	军事	64.44	85.71	85.71	85.71	100.00	75.79
20	电影	90.82	90.82	92.82	93.33	93.41	94.74
21	音乐	93.77	92.74	98.60	99.06	97.68	97.17
22	政治	79.00	80.32	82.10	82.58	85.61	81.45
23	科学	82.20	76.02	82.16	73.89	83.40	75.35
24	足球	98.59	98.58	98.58	98.35	98.58	98.35
25	股票与债券	80.83	75.15	78.73	70.62	77.89	76.19
26	监控	43.33	82.22	43.33	88.57	86.67	95.24
27	电视	83.12	64.96	84.24	83.37	84.42	81.82
28	网球	98.93	98.51	99.57	99.14	100.00	99.78
29	平价医疗法案	62.62	57.90	65.08	64.37	70.69	69.79

E　重复划分与训练预算结果

表 18: 重复划分结果，单位为百分比。每项为五个划分均值的均值与样本标准差。BERT 和 NYT Word2Vec 在每个划分内平均三个训练种子，稀疏模型拟合一次。传统模型读取全文，BERT 读取相应长度的前缀。

方法与损失	准确率	Macro-F1	低频类 F1
TF-IDF (加权)	94.18 ± 1.13	84.49 ± 2.75	76.08 ± 4.02
BERT-512 (加权)	93.62 ± 0.47	84.22 ± 0.87	76.56 ± 1.44
二值词袋 (加权)	93.87 ± 0.82	83.55 ± 2.26	75.01 ± 3.39
BERT-256 (加权)	93.29 ± 0.40	83.45 ± 1.27	74.87 ± 2.01
词频 (加权)	93.63 ± 0.88	83.35 ± 1.74	75.02 ± 2.39
TF-IDF (普通)	94.58 ± 0.82	83.22 ± 2.09	72.32 ± 3.41
词频 (普通)	93.55 ± 0.81	81.68 ± 2.17	71.18 ± 3.87
NYT W2V-IDF (普通)	93.02 ± 0.49	81.07 ± 0.62	70.51 ± 2.83
二值词袋 (普通)	93.56 ± 0.96	80.95 ± 2.01	69.02 ± 3.10
NYT W2V-IDF (加权)	92.09 ± 0.43	80.43 ± 1.37	70.14 ± 2.88
BERT-512 (普通)	94.54 ± 0.60	80.11 ± 1.34	65.17 ± 2.45
BERT-256 (普通)	94.14 ± 0.54	77.63 ± 2.10	58.84 ± 4.11

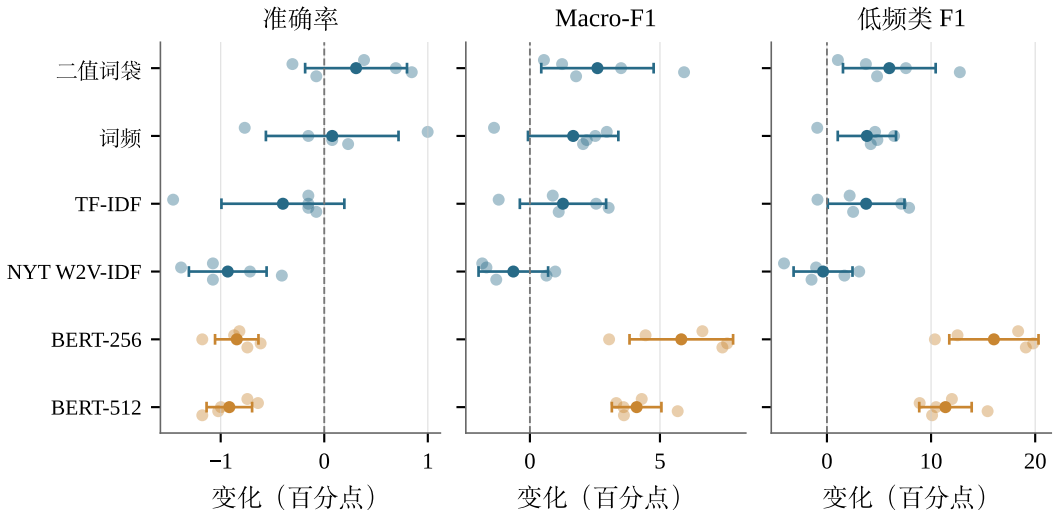


图 9: 五个配对划分上，加权相对普通损失的变化。散点为划分内平均训练种子后的差值，误差棒为五个差值的均值与样本标准差。所有传统表示均读取全文。

完整的 204 组配置及其预测保存于 `outputs/scaling/`。表 20–24 展示各划分均值。稀疏模型为单次拟合，BERT 和 NYT Word2Vec 平均三个训练种子，误差项为这些种子的样本标准差。

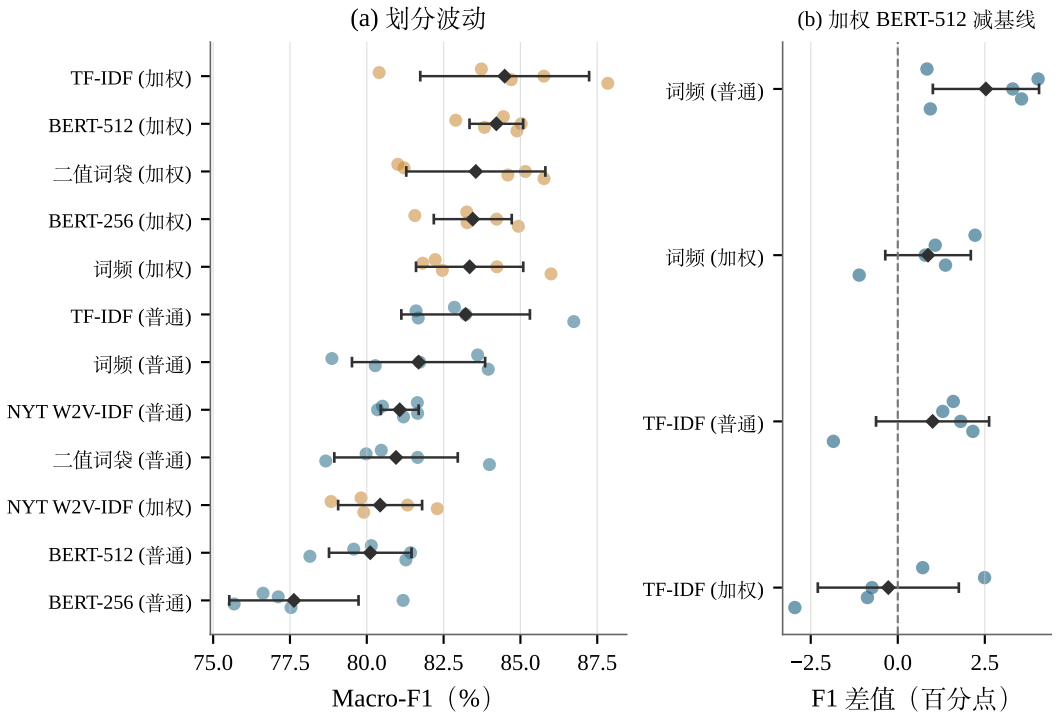


图 10: 划分敏感性。(a) 散点为五个划分均值，菱形与误差棒为其均值和样本标准差；橙色为加权损失，蓝色为普通损失。(b) 加权 BERT-512 相对全文稀疏基线的配对 Macro-F1 差值，误差棒描述划分波动。

表 19: 类别频次倒数加权的效果。每项为五个配对划分差值的均值与样本标准差，单位为百分点，训练种子先在划分内平均。

方法	Δ 准确率	ΔMacro-F1	Δ 低频类 F1
二值词袋	0.31 ± 0.49	2.60 ± 2.16	5.99 ± 4.45
词频	0.08 ± 0.64	1.66 ± 1.74	3.84 ± 2.80
TF-IDF	-0.40 ± 0.59	1.27 ± 1.66	3.76 ± 3.68
NYT W2V-IDF	-0.93 ± 0.38	-0.64 ± 1.34	-0.37 ± 2.83
BERT-256	-0.84 ± 0.21	5.82 ± 1.99	16.03 ± 4.29
BERT-512	-0.92 ± 0.22	4.10 ± 0.95	11.38 ± 2.52

表 20: 划分种子 42 的结果，单位为百分比；误差项描述训练种子波动。

方法与损失	准确率	Macro-F1	低频类 F1
TF-IDF (加权)	93.86	83.73	75.89
BERT-512 (加权)	93.45 ± 0.12	84.45 ± 0.59	78.43 ± 1.42
二值词袋 (加权)	92.86	81.01	71.56
BERT-256 (加权)	92.93 ± 0.08	83.26 ± 0.47	76.67 ± 1.25
词频 (加权)	92.86	82.23	75.54
TF-IDF (普通)	94.01	82.85	73.71
词频 (普通)	93.63	83.61	76.48
NYT W2V-IDF (普通)	92.73 ± 0.59	81.65 ± 0.59	74.18 ± 0.63
二值词袋 (普通)	92.47	80.47	70.51
NYT W2V-IDF (加权)	91.65 ± 0.19	79.81 ± 0.73	70.05 ± 1.58
BERT-512 (普通)	94.19 ± 0.23	80.15 ± 1.74	66.43 ± 4.73
BERT-256 (普通)	93.75 ± 0.18	76.62 ± 1.74	58.31 ± 4.26

表 21: 划分种子 43，报告方式与表 20 相同。

方法与损失	准确率	Macro-F1	低频类 F1
TF-IDF (加权)	92.78	80.40	69.47
BERT-512 (加权)	93.42 ± 0.42	82.90 ± 0.55	75.03 ± 0.31
二值词袋 (加权)	93.39	81.21	71.07
BERT-256 (加权)	93.11 ± 1.17	81.56 ± 3.58	71.48 ± 6.60
词频 (加权)	93.86	81.82	71.36
TF-IDF (普通)	94.24	81.60	70.38
词频 (普通)	92.86	78.87	66.74
NYT W2V-IDF (普通)	93.11 ± 0.23	80.51 ± 1.18	69.19 ± 2.54
二值词袋 (普通)	93.70	79.98	67.33
NYT W2V-IDF (加权)	91.73 ± 0.23	78.84 ± 0.83	68.14 ± 1.92
BERT-512 (普通)	94.06 ± 0.35	79.57 ± 2.45	66.12 ± 4.88
BERT-256 (普通)	93.98 ± 0.12	77.12 ± 3.09	58.95 ± 7.76

表 22: 划分种子 44 的结果，单位为百分比；误差项描述训练种子波动。

方法与损失	准确率	Macro-F1	低频类 F1
TF-IDF (加权)	95.01	85.76	77.22
BERT-512 (加权)	94.09 ± 0.13	85.02 ± 1.14	77.57 ± 3.17
二值词袋 (加权)	94.55	85.16	76.99
BERT-256 (加权)	93.68 ± 0.51	84.23 ± 0.67	76.02 ± 0.66
词频 (加权)	93.70	84.24	75.75
TF-IDF (普通)	95.16	83.22	70.08
词频 (普通)	93.86	81.72	69.30
NYT W2V-IDF (普通)	93.16 ± 0.31	80.35 ± 0.65	67.77 ± 0.91
二值词袋 (普通)	93.86	81.65	69.41
NYT W2V-IDF (加权)	92.45 ± 0.23	81.33 ± 0.34	70.87 ± 1.00
BERT-512 (普通)	95.08 ± 0.20	81.42 ± 2.12	67.10 ± 5.06
BERT-256 (普通)	94.85 ± 0.58	81.18 ± 2.58	65.65 ± 5.50

表 23: 划分种子 45，报告方式与表 20 相同。

方法与损失	准确率	Macro-F1	低频类 F1
TF-IDF (加权)	93.63	84.70	77.61
BERT-512 (加权)	93.04 ± 0.22	83.83 ± 0.22	76.37 ± 0.38
二值词袋 (加权)	93.70	84.59	77.61
BERT-256 (加权)	92.96 ± 0.36	83.27 ± 0.32	75.02 ± 0.95
词频 (加权)	92.78	82.46	74.53
TF-IDF (普通)	93.78	81.67	69.72
词频 (普通)	92.70	80.27	69.69
NYT W2V-IDF (普通)	92.40 ± 0.31	81.66 ± 1.29	72.86 ± 2.30
二值词袋 (普通)	92.86	78.66	64.85
NYT W2V-IDF (加权)	91.99 ± 0.51	82.29 ± 1.00	74.54 ± 2.24
BERT-512 (普通)	94.06 ± 0.16	78.15 ± 0.85	60.94 ± 2.26
BERT-256 (普通)	93.57 ± 0.12	75.68 ± 0.83	55.21 ± 2.54

表 24: 划分种子 46 的结果，单位为百分比；误差项描述训练种子波动。

方法与损失	准确率	Macro-F1	低频类 F1
TF-IDF (加权)	95.62	87.84	80.23
BERT-512 (加权)	94.11 ± 0.25	84.89 ± 0.43	75.38 ± 1.10
二值词袋 (加权)	94.85	85.77	77.81
BERT-256 (加权)	93.78 ± 0.48	84.93 ± 0.57	75.17 ± 1.00
词频 (加权)	94.93	86.00	77.93
TF-IDF (普通)	95.70	86.74	77.72
词频 (普通)	94.70	83.95	73.72
NYT W2V-IDF (普通)	93.70 ± 0.08	81.20 ± 0.25	68.57 ± 0.95
二值词袋 (普通)	94.93	83.99	73.00
NYT W2V-IDF (加权)	92.63 ± 0.15	79.90 ± 0.70	67.09 ± 2.15
BERT-512 (普通)	95.29 ± 0.09	81.27 ± 1.61	65.28 ± 3.91
BERT-256 (普通)	94.52 ± 0.12	77.53 ± 1.51	56.07 ± 3.88

表 25: 稀疏模型的匹配 256/512 词元前缀与全文对照，报告五个划分得分的均值与样本标准差。权重、词表和 IDF 均由对应训练划分拟合。

文本预算	方法与损失	准确率	Macro-F1	低频类 F1
全文	二值词袋 (普通)	93.56 ± 0.96	80.95 ± 2.01	69.02 ± 3.10
全文	二值词袋 (加权)	93.87 ± 0.82	83.55 ± 2.26	75.01 ± 3.39
全文	词频 (普通)	93.55 ± 0.81	81.68 ± 2.17	71.18 ± 3.87
全文	词频 (加权)	93.63 ± 0.88	83.35 ± 1.74	75.02 ± 2.39
全文	TF-IDF (普通)	94.58 ± 0.82	83.22 ± 2.09	72.32 ± 3.41
全文	TF-IDF (加权)	94.18 ± 1.13	84.49 ± 2.75	76.08 ± 4.02
256	二值词袋 (普通)	91.61 ± 0.68	76.79 ± 3.37	63.15 ± 7.38
256	二值词袋 (加权)	92.09 ± 0.83	80.21 ± 2.11	70.32 ± 4.02
256	词频 (普通)	91.89 ± 0.74	78.96 ± 2.05	68.43 ± 4.50
256	词频 (加权)	91.84 ± 0.62	79.67 ± 1.43	70.05 ± 3.46
256	TF-IDF (普通)	92.60 ± 0.68	78.27 ± 2.26	64.76 ± 4.94
256	TF-IDF (加权)	92.06 ± 1.10	81.86 ± 2.08	73.96 ± 4.03
512	二值词袋 (普通)	93.41 ± 1.08	80.03 ± 2.72	66.86 ± 4.65
512	二值词袋 (加权)	93.29 ± 1.14	81.67 ± 2.53	71.00 ± 3.04
512	词频 (普通)	92.84 ± 0.58	80.65 ± 1.94	70.24 ± 3.59
512	词频 (加权)	93.03 ± 0.42	82.08 ± 2.16	73.24 ± 4.45
512	TF-IDF (普通)	93.92 ± 0.72	82.09 ± 2.11	70.93 ± 4.59
512	TF-IDF (加权)	93.63 ± 1.04	83.72 ± 2.63	75.62 ± 4.53

E.1 优化预算

预算对照保持输入、初始化种子、优化器常量和检查点选择规则一致。各运行完成指定轮数，并采用相应的预热与衰减调度。表 26 的选择轮次依次对应训练种子 42、43、44。

表 26: 划分 42 上的三轮与十轮 BERT 对照。分数为三个训练种子的均值与样本标准差，选择列为验证集选定的轮次。

长度	损失	轮数	准确率	Macro-F1	低频类 F1	选择轮次
64	普通	3	89.96 ± 0.45	65.60 ± 3.27	36.24 ± 7.11	3,3,3
64	普通	10	90.58 ± 0.51	79.80 ± 1.96	72.81 ± 3.31	10,10,8
64	加权	3	89.68 ± 0.19	79.53 ± 1.46	72.85 ± 2.85	3,3,3
64	加权	10	90.63 ± 0.46	80.59 ± 0.37	74.25 ± 0.95	4,10,6
256	普通	3	93.75 ± 0.18	76.62 ± 1.74	58.31 ± 4.26	3,3,3
256	普通	10	94.29 ± 0.66	85.48 ± 2.84	78.49 ± 5.58	6,9,4
256	加权	3	92.93 ± 0.08	83.26 ± 0.47	76.67 ± 1.25	3,3,3
256	加权	10	93.75 ± 0.29	84.46 ± 0.81	77.41 ± 0.83	4,4,4
512	普通	3	94.19 ± 0.23	80.15 ± 1.74	66.43 ± 4.73	3,3,3
512	普通	10	94.96 ± 0.29	86.38 ± 0.51	79.53 ± 0.91	5,10,4
512	加权	3	93.45 ± 0.12	84.45 ± 0.59	78.43 ± 1.42	3,3,3
512	加权	10	94.21 ± 0.70	85.72 ± 1.33	79.58 ± 1.83	9,3,4

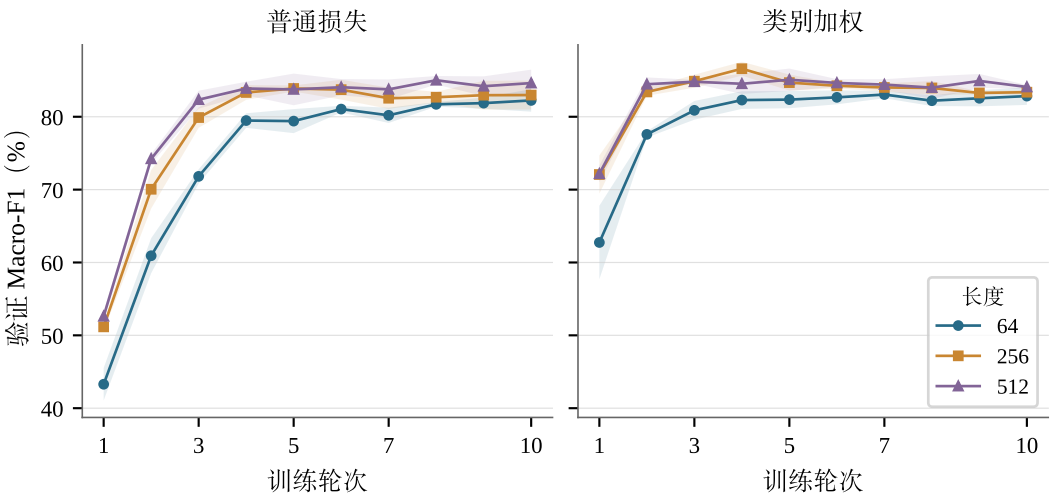


图 11: 三种长度下十轮训练的验证 Macro-F1。曲线为三个训练种子的均值，阴影为样本标准差，各运行单独选择检查点。

E.2　文本位置与逐类加权效果

表 27: 划分 42 上加权 BERT-256 的位置对照。每组使用三轮训练与 254 个文本词元；头尾各半拼接前后各 127 个 WordPiece。分数为三个训练种子的均值与样本标准差。

文本位置	准确率	Macro-F1	低频类 F1
头部	92.93 ± 0.08	83.26 ± 0.47	76.67 ± 1.25
尾部	89.99 ± 0.25	76.22 ± 0.37	63.70 ± 1.59
头尾各半	92.45 ± 0.09	81.57 ± 1.31	72.51 ± 3.01

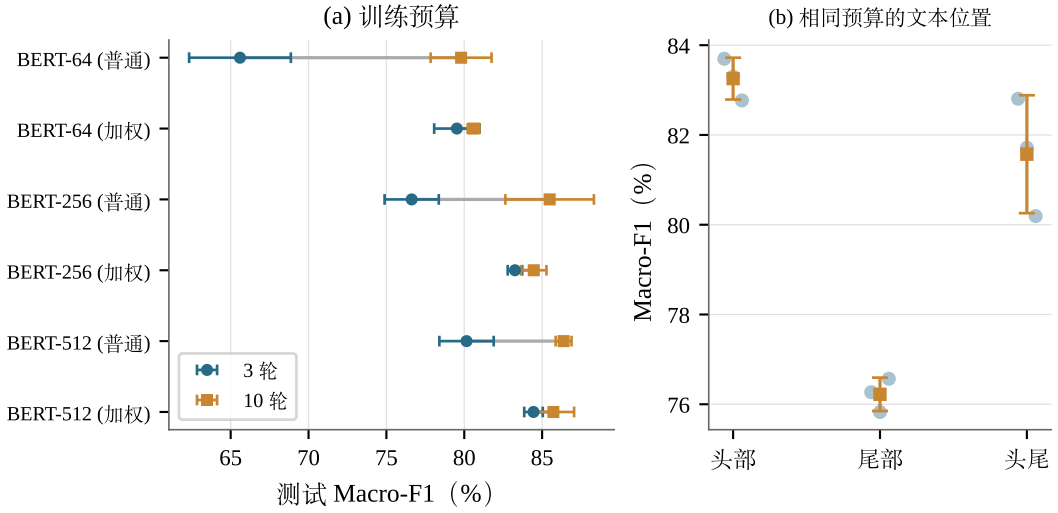


图 12: 固定划分对照。(a) 三轮与十轮训练的测试 Macro-F1，误差棒为三个种子的样本标准差。(b) 加权 BERT-256 固定预算下的文本位置，浅色散点为各训练种子。

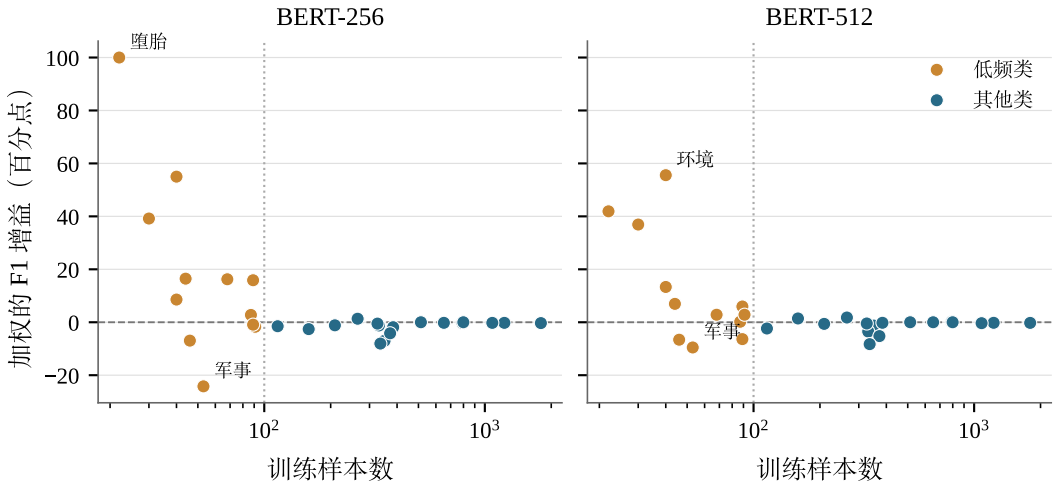


图 13: 划分 42 上训练频次与类别加权效果。各点为对应类别在三个配对种子上的平均 F1 增益，横轴使用对数刻度，橙色表示训练文档不超过 100 的类别。负值表示加权后的 F1 下降。